



NOVA
IMS
Information
Management
School

Data Mining

Descriptive Methods

Hierarchical Algorithms

Fernando Lucas Bação
bação@isegi.unl.pt
<http://www.isegi.unl.pt/flbação>
Instituto Superior de Estatística e Gestão de Informação
Universidade Nova de Lisboa

1



NOVA
IMS
Information
Management
School

AGENDA

- Cluster analysis
 - Clustering techniques
 - Hierarchical Methods (agglomerative)

Instituto Superior de Estatística e Gestão de Informação
Universidade Nova de Lisboa

2

NOVA
IMS
Information Management School

Clustering

Instituto Superior de Estatística e Gestão de Informação
Universidade Nova de Lisboa













3

NOVA
IMS
Information Management School

Clustering



```

graph TD
    Grouping --> Clustering
    Grouping --> CellBasedSegments[Cell-based segments]
    Clustering --> HierarchicalMethods[Hierarchical Methods]
    Clustering --> PartitionMethods[Partition Methods]
    Clustering --> DBScan[DBScan]
    Clustering --> ShiftMean[Shift mean]
    Clustering --> SelfOrganizingMaps[Self-Organizing Maps]
    CellBasedSegments --> Variables[Variables]
    CellBasedSegments --> ThroughTime[Through time]
    CellBasedSegments --> RFMAnalysis[RFM Analysis]
  
```

Instituto Superior de Estatística e Gestão de Informação
Universidade Nova de Lisboa

4

NOVA
IMS
Information Management School

Hierarchical Methods

Instituto Superior de Estatística e Gestão de Informação
Universidade Nova de Lisboa

UNIS
A3ES
Schools
eduniversal

5

NOVA
IMS
Information Management School

Clustering

- Hierarchical Clustering**

	X_1	X_2	...	X_p
I_1				
I_2				
...				
I_q				

Instituto Superior de Estatística e Gestão de Informação
Universidade Nova de Lisboa

6

NOVA
IMS
Information Management School

Clustering

- Hierarchical Clustering**

$$d_{ij} = \sqrt{\sum_{v=1}^p (x_{iv} - x_{jv})^2}$$

	X_1	X_2	...	X_p
I_1				
I_2				
...				
I_n				

	I_1	I_2	...	I_n
I_1	0			
I_2	$d(I_2, I_1)$	0		
...	$d(I_1, I_1)$	$d(I_1, I_2)$	0	
I_n	$d(I_n, I_1)$	$d(I_n, I_2)$	$d(I_n, I_1)$	0

Instituto Superior de Estatística e Gestão de Informação
Universidade Nova de Lisboa

7

NOVA
IMS
Information Management School

Clustering

- Hierarchical Clustering**
 - Distance matrix

Input distance matrix:

	BOS	NY	DC	MIA	CHI	SEA	SF	LA	DEN
BOS	0	206	429	1504	963	2976	3095	2979	1949
NY	206	0	233	1308	802	2815	2934	2786	1771
DC	429	233	0	1075	671	2684	2799	2631	1616
MIA	1504	1308	1075	0	1329	3273	3053	2687	2037
CHI	963	802	671	1329	0	2013	2142	2054	996
SEA	2976	2815	2684	3273	2013	0	808	1131	1307
SF	3095	2934	2799	3053	2142	808	0	379	1235
LA	2979	2786	2631	2687	2054	1131	379	0	1059
DEN	1949	1771	1616	2037	996	1307	1235	1059	0

Instituto Superior de Estatística e Gestão de Informação
Universidade Nova de Lisboa

8

NOVA
IMS
Information
Management
School

Clustering

- Hierarchical Clustering**
 - Linkage or Aggregation Rules

Single Linkage

Complete Linkage

Instituto Superior de Estatística e Gestão de Informação
Universidade Nova de Lisboa

9

NOVA
IMS
Information
Management
School

Clustering

- Hierarchical Clustering**
 - Linkage or Aggregation Rules

Average Linkage

Average Group Linkage (centroid)

Instituto Superior de Estatística e Gestão de Informação
Universidade Nova de Lisboa

10

NOVA
IMS
Information
Management
School

Clustering

- Hierarchical Clustering**
 - Distance matrix

After merging BOS with NY:

	BOS/NY	DC	MIA	CHI	SEA	SF	LA	DEN
BOS/NY	0	223	1308	802	2815	2934	2786	1771
DC	223	0	1075	671	2684	2799	2631	1616
MIA	1308	1075	0	1329	3273	3053	2687	2037
CHI	802	671	1329	0	2013	2142	2054	996
SEA	2815	2684	3273	2013	0	808	1131	1307
SF	2934	2799	3053	2142	808	0	379	1235
LA	2786	2631	2687	2054	1131	379	0	1059
DEN	1771	1616	2037	996	1307	1235	1059	0

Instituto Superior de Estatística e Gestão de Informação
Universidade Nova de Lisboa

11

NOVA
IMS
Information
Management
School

Clustering

- Hierarchical Clustering**
 - Distance matrix

After merging DC with BOS-NY:

	BOS/NY/DC	MIA	CHI	SEA	SF	LA	DEN
BOS/NY/DC	0	1075	671	2684	2799	2631	1616
MIA	1075	0	1329	3273	3053	2687	2037
CHI	671	1329	0	2013	2142	2054	996
SEA	2684	3273	2013	0	808	1131	1307
SF	2799	3053	2142	808	0	379	1235
LA	2631	2687	2054	1131	379	0	1059
DEN	1616	2037	996	1307	1235	1059	0

Instituto Superior de Estatística e Gestão de Informação
Universidade Nova de Lisboa

12

NOVA
IMS
Information
Management
School

Clustering

- Hierarchical Clustering**
 - Dendrogram

Instituto Superior de Estatística e Gestão de Informação
Universidade Nova de Lisboa

13

NOVA
IMS
Information
Management
School

Clustering

	BA	FI	MI	NA	RM	TO
BA	0	662	877	255	412	996
FI	662	0	295	468	268	400
MI	877	295	0	754	564	138
NA	255	468	754	0	219	869
RM	412	268	564	219	0	669
TO	996	400	138	869	669	0

Instituto Superior de Estatística e Gestão de Informação
Universidade Nova de Lisboa

14

NOVA
IMS
Information
Management
School

Clustering

	BA	FI	MI/TO	NA	RM
BA	0	662	877	255	412
FI	662	0	295	468	268
MI/TO	877	295	0	754	564
NA	255	468	754	0	219
RM	412	268	564	219	0

Instituto Superior de Estatística e Gestão de Informação
Universidade Nova de Lisboa

15

NOVA
IMS
Information
Management
School

Clustering

	BA	FI	MI/TO	NA/RM
BA	0	662	877	255
FI	662	0	295	268
MI/TO	877	295	0	564
NA/RM	255	268	564	0

Instituto Superior de Estatística e Gestão de Informação
Universidade Nova de Lisboa

16

NOVA
IMS
Information
Management
School

Clustering

	BA/NA/RM	FI	MI/TO
BA/NA/RM	0	268	564
FI	268	0	295
MI/TO	564	295	0

Instituto Superior de Estatística e Gestão de Informação
Universidade Nova de Lisboa

17


NOVA
IMS
Information
Management
School

Clustering


	BA/FI/NA/RM	MI/TO
BA/FI/NA/RM	0	295
MI/TO	295	0

Instituto Superior de Estatística e Gestão de Informação
Universidade Nova de Lisboa

18



19



20

NOVA

IMS

Information
Management
School

Clustering

- **Hierarchical Clustering**
 - Hierarchical Clustering - Interactive demo
 - You can find a nice worked example of hierarchical clustering at:

<https://claude.ai/public/artifacts/a12a6e5c-f34d-4a4e-a81b-a5ddc8df8917>

Instituto Superior de Estatística e Gestão de Informação
 Universidade Nova de Lisboa

21

NOVA

IMS

Information
Management
School

Clustering

- **Hierarchical Clustering (disadvantages)**
 - Have an essential problem, once an interaction is performed (merge or separation) we **cannot go back**;
 - This strictness is useful in terms of **computacional costs**, because it avoids the cost that originates from the different combinatorial choices;
 - However, this low cost is related to the **impossibility to correct wrong decisions**;
 - Due to its calculation needs, several operations with large matrices **do not always work very well with large datasets**.

Instituto Superior de Estatística e Gestão de Informação
 Universidade Nova de Lisboa

22

NOVA
IMS
Information
Management
School

Clustering

- **Hierarchical Clustering (other variants)**
 - There are two ways of improving the performance of hierarchical methods:
 - To perform a careful analysis of the links produced in each hierarchical partition (CURE and Chameleon methods);
 - To integrate hierarchical clustering and optimization, first using an agglomerative algorithm and then refining the results by using iterative optimization (BIRCH method).

Instituto Superior de Estatística e Gestão de Informação
Universidade Nova de Lisboa

23

Questions?

24

24